

Praktikum 2: Analisis Statistik Deskriptif dan Visualisasi Data Menggunakan Pandas dan Matplotlib

Monika Septiana - 0110222127^{1*}

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: moni22127ti@student.nurulfikri.ac.id

Abstract. Pada praktikum ini dilakukan analisis data menggunakan bahasa pemrograman Python dengan bantuan pustaka Pandas, NumPy, Matplotlib, dan Seaborn di lingkungan Google Colab. Tujuan utama kegiatan ini adalah untuk memahami dan menerapkan konsep statistik deskriptif serta probabilitas dasar dalam konteks machine learning. Dataset yang digunakan berisi informasi mengenai jenis kelamin (Gender), tinggi badan (Height), berat badan (Weight), dan indeks tubuh (Index) dari 500 individu.

Langkah-langkah yang dilakukan meliputi pembacaan dataset, eksplorasi struktur data menggunakan fungsi `info()` dan `describe()`, perhitungan ukuran pemusatan (mean, median, modus), ukuran penyebaran (variansi, standar deviasi, dan interquartile range), serta analisis korelasi antar variabel. Selain itu, dibuat pula berbagai visualisasi data berupa boxplot, histogram, dan scatter plot untuk menggambarkan distribusi dan hubungan antar variabel secara visual.

Hasil analisis menunjukkan bahwa data memiliki distribusi yang cukup seimbang antara variabel tinggi dan berat badan, dengan korelasi positif antara Weight dan Index, serta korelasi negatif antara Height dan Index. Praktikum ini juga melatih kemampuan mahasiswa dalam memahami karakteristik data sebelum melanjutkan ke tahap pemodelan machine learning.

1. Pendahuluan

Pada era perkembangan teknologi informasi saat ini, machine learning menjadi salah satu bidang yang banyak digunakan untuk membantu pengambilan keputusan berbasis data. Sebelum melakukan proses pelatihan model, tahap yang paling penting adalah memahami karakteristik data melalui analisis statistik deskriptif dan probabilitas dasar. Analisis ini memungkinkan peneliti untuk mengenali pola, nilai ekstrem, serta hubungan antar variabel yang nantinya berpengaruh terhadap performa model machine learning.

Praktikum ini dilaksanakan menggunakan bahasa pemrograman Python pada platform Google Colab, yang memungkinkan pengguna untuk menjalankan kode Python secara langsung di peramban tanpa konfigurasi tambahan. Dataset yang digunakan berisi 500 data individu dengan atribut Gender, Height, Weight, dan Index. Melalui dataset ini, mahasiswa diharapkan

dapat memahami konsep pengolahan data, perhitungan ukuran pemusatan dan penyebaran, serta membuat visualisasi data menggunakan pustaka Pandas, NumPy, Matplotlib, dan Seaborn.

Selain itu, metode analisis statistik juga memiliki keterkaitan erat dengan pengembangan model prediktif. Misalnya, algoritma Random Forest Regression (RFR) telah digunakan untuk memprediksi kandungan nutrisi makro daun kelapa sawit (Munir et al., 2022), dan model tersebut diterapkan pada sistem PRECIPALM, yaitu sistem rekomendasi pemupukan berbasis citra satelit (Seminar et al., 2024). Contoh tersebut menunjukkan pentingnya pemahaman statistik dalam mendukung penerapan model machine learning di berbagai bidang.

1.1 Latar Belakang

Sebelum membangun suatu model machine learning, tahap awal yang harus dilakukan adalah eksplorasi data (data understanding). Proses ini mencakup pengumpulan, pembersihan, dan analisis statistik awal terhadap dataset yang digunakan. Dengan memahami karakteristik data, seperti nilai rata-rata, median, modus, serta tingkat persebaran data (variansi dan standar deviasi), pengguna dapat menentukan strategi pemodelan yang lebih akurat dan efisien.

Selain itu, visualisasi data juga berperan penting dalam membantu interpretasi hasil analisis. Melalui grafik seperti boxplot, histogram, dan scatter plot, hubungan antar variabel dapat dilihat dengan lebih intuitif. Oleh karena itu, penguasaan terhadap dasar statistik deskriptif menjadi fondasi penting dalam proses pembelajaran mesin dan analisis data secara menyeluruh.

2. Metodologi Penelitian

Metodologi pada praktikum ini berfokus pada penerapan konsep statistik deskriptif dan probabilitas dasar menggunakan bahasa pemrograman Python di lingkungan Google Colab. Proses ini dilakukan untuk memahami struktur dan karakteristik dataset sebelum digunakan dalam model machine learning.

Langkah-langkah pelaksanaan meliputi persiapan lingkungan kerja, pemrosesan data, analisis statistik, hingga visualisasi hasil menggunakan berbagai teknik grafik. Setiap tahap dirancang agar mahasiswa dapat memahami konsep statistik secara teoritis maupun praktis melalui eksplorasi data nyata.

2.1 Persiapan Lingkungan Pengembangan

Langkah pertama adalah menyiapkan lingkungan kerja menggunakan Google Colab, karena platform ini menyediakan akses Python berbasis cloud tanpa perlu instalasi lokal. Colab juga memudahkan integrasi dengan Google Drive untuk menyimpan dataset dan notebook.

Tahapan yang dilakukan:

1. Melakukan mounting Google Drive agar Colab dapat mengakses file pada Drive.
2. Membuat struktur folder praktikum_ml/praktikum02 dengan subfolder data, notebooks, models, dan reports.
3. Mengimpor pustaka utama: Pandas, NumPy, Matplotlib, dan Seaborn.

2.2 Pengolahan dan Analisis Data

Setelah lingkungan siap, dilakukan pembacaan dataset 500_Person_Gender_Height_Weight_Index.csv menggunakan pustaka Pandas. Data tersebut berisi 500 baris dengan empat kolom utama, yaitu Gender, Height, Weight, dan Index. Analisis dilakukan dalam beberapa tahap berikut:

1. Eksplorasi Data Awal:

Melihat struktur data (`df.info()`), tipe data, dan menampilkan beberapa baris awal (`df.head()`).

2. Analisis Statistik Deskriptif:

Menghitung nilai rata-rata (mean), median, modus, variansi, dan standar deviasi untuk setiap kolom numerik. Selain itu, dilakukan pula perhitungan kuartil (Q1 dan Q3) serta Interquartile Range (IQR) untuk memahami penyebaran data.


3. Analisis Korelasi:

Menggunakan metode `df.corr()` untuk melihat hubungan antar variabel numerik, seperti hubungan antara tinggi badan (Height) dan berat badan (Weight).


2.3 Visualisasi Data

Visualisasi data digunakan untuk menggambarkan pola dan distribusi secara grafis agar lebih mudah dianalisis. Beberapa jenis grafik yang dibuat dalam praktikum ini meliputi:


1. Boxplot: Menunjukkan distribusi data Height dan Weight serta potensi nilai pencilan (outlier).
2. Histogram: Menggambarkan distribusi frekuensi data Height dalam lima kelompok (bins).
3. Scatter Plot: Menampilkan hubungan antar variabel numerik, termasuk contoh korelasi positif dan negatif.




Gambar 1. Visualisasi Boxplot antara variabel Height dan Weight.



Gambar 2. Histogram distribusi tinggi badan



Gambar 3. Scatter Plot Korelasi Positif



Gambar 4. Scatter Plot Korelasi Negatif

Table 1. Ringkasan Tahapan Analisis Statistik dan Visualisasi Data

Tahapan Analisis	Deskripsi Kegiatan	Library yang Digunakan	Keterangan
Pembacaan Data	Membaca file CSV berisi data <i>Gender, Height, Weight</i> , dan <i>Index</i> menggunakan <code>pandas.read_csv()</code>	Pandas	Dataset terdiri dari 500 entri dan 4 kolom
Statistik Deskriptif	Menghitung mean, median, modus, variansi, dan standar deviasi dari kolom numerik	Pandas, NumPy	Digunakan untuk memahami persebaran data
Analisis Korelasi	Mengukur hubungan linear antar variabel numerik dengan <code>df.corr()</code>	Pandas	Korelasi positif antara <i>Weight</i> dan <i>Index</i>
Visualisasi Boxplot	Membuat boxplot untuk melihat distribusi dan <i>outlier</i> pada data tinggi dan berat badan	Matplotlib	Menggambarkan persebaran data Height dan Weight
Visualisasi Histogram	Menampilkan distribusi frekuensi tinggi badan dalam beberapa kelompok (<i>bins</i>)	Matplotlib	Menunjukkan pola distribusi data Height
Visualisasi Scatter Plot	Membuat diagram pencar untuk melihat hubungan antar dua variabel	Matplotlib	Menunjukkan korelasi positif dan negatif antar variabel

Catatan: Tabel ini merangkum seluruh tahapan yang dilakukan selama praktikum 2 untuk memahami karakteristik data dan hubungan antar variabel sebelum tahap pemodelan machine learning.

Referensi:

Munir, S., Seminar, K. B., Sudradjat, Sukoco, H., & Buono, A. (2022). The Use of Random Forest Regression for Estimating Leaf Nitrogen Content of Oil Palm Based on Sentinel 1-A Imagery. *Information*, 14(1), 10. <https://doi.org/10.3390/info14010010>

Seminar, K. B., Imantho, H., Sudradjat, Yahya, S., Munir, S., Kaliana, I., Mei Haryadi, F., Noor Baroroh, A., Supriyanto, Handoyo, G. C., Kurnia Wijayanto, A., Ijang Wahyudin, C., Liyantono, Budiman, R., Bakir Pasaman, A., Rusiawan, D., & Sulastri. (2024). PreciPalm: An Intelligent System for Calculating Macronutrient Status and Fertilizer Recommendations for Oil Palm on Mineral Soils Based on a Precision Agriculture Approach. *Scientific World Journal*, 2024(1). <https://doi.org/10.1155/2024/1788726>